

Práctica Machine Learning I

IMMUNE
Numerai

Predict the stock market

La práctica *machine learning* más difícil del mundo:

Predecir el mercado de valores

- Datos regularizados y ofuscados provenientes de datos financieros.
- Construye tu primer modelo base y comienza desde aquí:

practicaMLI.ipynb

Data

El dataset es un conjunto de datos tabular que describe el mercado de valores mundial a lo largo del tiempo.

id	era	feature1	...	feature310	target
n2b2e3dd163cb422	era1	0.75	...	0.00	0.25
n177021a571c94c8	era1	1.00	...	0.25	0.75
n7830fa4c0cd8466	era1	0.25	...	1.00	0.00
nc584a184cee941b	era1	0.25	...	0.00	1.00
nc5ab8667901946a	era1	0.75	...	0.25	0.25
n84e624e4714a7ca	era1	0.00	...	0.75	1.00

Data

Cada fila representa una acción en un momento específico.

Donde “id” es la identificación de la acción (stock) y “era” es la fecha.

Las features describen los atributos de la acción (por ejemplo, la relación P/E: precio/beneficio) conocidos en esa fecha.

$P/E = \text{precio por acción} / \text{beneficios anuales por acción}$

Si P/E alto -> podría estar sobrevalorada o tener expectativas altas de crecimiento

Si P/E bajo -> infravalorada o expectativas bajas

Y el “target” es una media de los rendimientos futuros (por ejemplo, después de 20 días de la fecha)

Data: features

Las características del conjunto de datos representan desde fundamentos como la relación P/E (price/earn), hasta señales técnicas como el RSI (índice de fuerza relativa), datos de mercado como intereses a corto plazo, datos secundarios como calificaciones de analistas y mucho más.

Se recomienda no crear modelos que dependan demasiado de una pequeña cantidad de características porque podrían producir un rendimiento inconsistente.

Si encuentras algún NaN en algún valor, elige por ti mismo cómo manejarlo.

Data: targets

El “target” principal se puede interpretar como rendimientos específicos de acciones que no se explican por tendencias como el mercado/país/sector o factores bien conocidos.

En términos financieros cuantitativos, se busca “alfa”:

- Capacidad de un fondo o estrategia de inversión para superar el rendimiento del mercado.
- En términos técnicos, alfa representa el rendimiento de una inversión que no se puede explicar por los movimientos del mercado en general o por factores de riesgo conocidos. Es decir, rendimientos generados específicamente por la selección de acciones individuales o decisiones de inversión, y no por movimientos generales del mercado.

Data: eras

Las “eras” representan diferentes momentos en el tiempo, donde los valores de las “features” son en ese momento y los valores “target” miran hacia adelante en relación a ese momento.

En lugar de tratar cada fila como un único punto de datos, puedes considerar tratar cada “era” como un único punto de datos. Las métricas pueden realizarse agrupadas por “era”, por ejemplo, la correlación media por era.

En los datos históricos (entrenamiento y validación), las “eras” tienen una diferencia de una semana, pero los “target” son a 20 ó 60 días vista. Esto significa que los “target” se “superponen”, por lo que se debe tener especial cuidado al validar.

Scoring: Correlation (CORR)

La principal métrica de puntuación es la correlación entre las predicciones del modelo y el “target”. Esta métrica “Corr”, a alto nivel, está diseñada para ser un buen indicador de los rendimientos reales de la cartera si las predicciones fueran utilizadas en operaciones reales.

¿Qué hacer?

Partiendo del notebook **practicaMLI.ipynb**, realiza los siguientes pasos:

- 1.- Dataset (exploration and preprocessing) **3 puntos**
- 2.- Modeling **2 puntos**
- 3.- Validation **2 puntos**
- 4.- Improvement **2 puntos**
- 5.- Submission **1 punto**

Dataset (3 puntos)

Explora el dataset, visualízalo y realiza el preprocesamiento que necesites:

- Muestra las gráficas que consideres necesarias y explica su importancia.
- Reduce el conjunto de datos, eliminando filas (si así lo consideras), si se vuelve muy pesado el entrenamiento. Justifícalo.
- Comprueba que mejore la precisión eliminando características poco relevantes. Explica qué métodos o criterios has usado para eliminar características y por qué.
- Aplica PCA para reducir la dimensionalidad. ¿Cuántas características resultan y por qué?
- Comprueba y explica por qué mejora, o no, la precisión respecto a entrenar el modelo con todas las features.
- ¿Has aplicado preprocesamiento? ¿escalado/normalización o estandarización? ¿por qué?

Modeling (2 puntos)

Antes de entrenar el modelo, puedes dividir el conjunto de datos train original en entrenamiento y test. Explica cómo lo has hecho.

Después, una vez seleccionado el modelo y sus hiper parámetros, validaremos el resultado con los datos de test, y por último, con los de validación (lo haremos como en el notebook inicial).

En este punto, explica el concepto de overfitting y cómo se evita.

Entrena el modelo con cualquier algoritmo visto en clase (puedes elegir uno o varios para probar). Si usas LGBMRegressor, obligatoriamente, usa además otro visto en clase. Argumenta por qué lo has elegido respecto a otros. Es decir, por qué descartas usar los otros y no éste.

Validation (2 puntos)

Explica cómo has evaluado los resultados. ¿Por qué aplica en este caso el uso de coeficiente de correlación de Pearson y no, por ejemplo, F1_score? Explica las diferencias.

Muestra cuantitativa y gráficamente el resultado CORR de la evaluación. Explícalo.

Calcula también las métricas de rendimiento (ver ejemplo) y explica el resultado.

Improvement & Investigation (2 puntos)

Una cosa que hace que predecir el mercado de valores sea tan difícil es que la relación entre las “features” y los rendimientos es “no estacionaria”.

Es decir, las características que tienen un fuerte poder predictivo durante algunos períodos de tiempo pueden no tenerlo en otros períodos diferentes, o incluso revertirse por completo. Esta incertidumbre es lo que llamamos “feature risk”.

Para crear modelos que tengan un rendimiento consistente, a menudo resulta útil limitar su “feature risk” con el método conocido como “feature neutralization”.

- Si quieres mejorar el rendimiento de tu modelo, investiga sobre **Feature neutralization** (muy utilizada en el ámbito de las finanzas cuantitativas), explica cómo funciona y trata de aplicarlo.

Alternativamente, puedes aplicar otra/s mejora/s diferente/s a esta, como podría ser **Ridge Regression** (funciona bien cuando tenemos muchas características ligeramente útiles en la predicción), explicándola/s y justificándola/s.

Submission (1 punto)

- Cómo podrías generar un artefacto (serializar tu función resultante) y guardarla en disco y exportarla? Echa un ojo a la librería *cloudpickle* por ejemplo.

Finalmente, después de algunos días, probaré tu función serializada (artefacto), para comprobar qué tal se comporta con nuevos datos reales (ver notebook base).